Introducción a los modelos de Record Linkage

Andrés Gutiérrez - División de Estadísticas de la CEPAL

En este repositorio me propongo desarrollar, de manera detallada y progresiva, tanto la teoría como algunos elementos prácticos del *record linkage*, tomando como eje tres hitos fundamentales en la literatura:

1. El modelo clásico de comparación de pares de Fellegi-Sunter (1969)
2. El modelo de *matching* con errores de medición en las covariables (*Hit-Miss*) de Copas y Hilton (1990)
3. El modelo de *matching* bipartito propuesto por Sadinle (2014)

Más que un manual exhaustivo o una referencia definitiva, este repositorio nace como un ejercicio personal: un intento de organizar, comprender y explicar estos modelos desde sus fundamentos estadísticos y matemáticos, motivado principalmente por mi curiosidad intelectual. En ese sentido, el énfasis está puesto en descomponer las ideas, hacer explícitas las suposiciones y recorrer paso a paso las estructuras probabilísticas que sustentan cada enfoque.

El hilo conductor de esta exploración es la inferencia bayesiana, que permite unificar de manera natural los distintos modelos bajo un mismo marco conceptual. Por esta razón, además del desarrollo teórico, incluyo implementaciones computacionales que buscan reflejar fielmente las formulaciones probabilísticas. Dichas implementaciones están escritas en STAN, no sólo como herramienta de cálculo, sino también como un lenguaje que ayuda a traducir la teoría en modelos explícitos y reproducibles.

En síntesis, este repositorio debe entenderse como una especie de cuaderno de trabajo extendido: un espacio donde la teoría, la modelación y la implementación dialogan constantemente, con el objetivo principal de profundizar en la comprensión del *record linkage* desde una perspectiva rigurosa pero también exploratoria.

El modelo de Fellegi-Sunter

El **record linkage** es el proceso de identificar registros que corresponden a la misma entidad (por ejemplo, la misma persona) en diferentes bases de datos. Su objetivo es determinar si un par de registros corresponde a:

- **Match**: la misma entidad
- **No match**: entidades diferentes

El enfoque probabilístico modela esta decisión utilizando probabilidades en lugar de reglas determinísticas. Para cada par construimos un **vector de comparaciones**:

$$X_i = (X_{i1}, X_{i2}, ..., X_{iK})$$

En donde, K representa el número de variables que se utilizan en la comparación, X_{ik} es un indicador de coincidencia en la variable k, definido por:

$$X_{ik} = \begin{cases} 1 & \text{si hay coincidencia} \\ 0 & \text{si no coincide} \end{cases}$$

Por ejemplo, si se consideran tres variables de comparación (nombre, apellido y fecha de nacimiento) y $X_i = (1, 1, 0)$, es porque, para ese par específico hay coincidencia en las primeras dos variables (nombre y apellido), pero no en la última (fecha de nacimiento).

Enfoque probabilístico

En las aplicaciones prácticas nunca sabremos si una entidad en una lista realmente coincide con otra entidad en otra lista, por eso es necesario crear una variable latente que pueda modelar este proceso de identificación. De esta forma, para cada par, introducimos la variable no observable, Z_i, definida así:

$$Z_i = \begin{cases} 1 & \text{si el par es match} \\ 0 & \text{si el par no es match} \end{cases}$$

Por tanto, nuestro objetivo será calcular la probabilidad de que un par de registros corresponda a la misma entidad (match) $\pi = P(Z = 1)$. Como estamos involucrando un conjunto de variables de comparación, entonces para cada par debemos calcular la probabilidad condicionada a X_i, así:

$$P(Z_i = 1|X_i)$$

Esto es, la probabilidad de que dos registros correspondan a la misma persona dado su patrón de coincidencias. En muchos contextos se espera que esta probabilidad sea pequeña, porque la mayoría de los pares posibles no corresponderán al mismo registro.

En el modelo probabilístico de record linkage, cada variable de comparación puede tener un comportamiento distinto en términos de su capacidad para coincidir cuando dos registros pertenecen realmente a la misma entidad. Por esta razón, el modelo introduce un parámetro específico para cada variable:

$$m_k = P(X_k = 1|Z = 1)$$

Estos parámetros representan la probabilidad de coincidencia cuando el par sí es match. La razón por la cual cada variable tiene asociada su propio parámetro es que no todas las variables son igual de confiables ni presentan los mismos niveles de error o variabilidad en las bases de datos. Por ejemplo:

1. El nombre puede coincidir en la mayoría de los casos cuando se trata de la misma persona, pero puede haber discrepancias debido a errores de digitación. Por esta razón, podríamos tener una probabilidad como $m_{nombre} = 0.9$. Esto significa que incluso cuando los registros corresponden a la misma persona, existe un 10% de probabilidad de que los nombres no coincidan exactamente.
2. Los apellidos suelen ser más estables que los nombres, aunque todavía pueden ocurrir discrepancias debido a errores de digitación, o diferencias en acentuación ("Pérez" vs "Perez"). Debido a esta mayor estabilidad, podría ser razonable que $m_{apellido} = 0.9$. Lo que indica que solo en un 5% de los casos habría discrepancia incluso cuando se trata de la misma persona.
3. La fecha de nacimiento suele ser una variable altamente informativa y relativamente estable. Cuando los registros corresponden a la misma persona, lo normal es que coincida exactamente. Sin embargo, pueden existir errores debido a formatos distintos de fecha ("03/11/1988" vs "11/03/1988"). Si estos errores son menos frecuentes, podríamos tener $m_{fecha} = 0.98$. Lo que indicaría que solo en un 2% de los casos habría discrepancia incluso cuando los registros son realmente del mismo individuo.

Variable	m_k
nombre	0.90
apellido	0.95

Variable	m_k
fecha nacimiento	0.98

Ahora, asumiendo independencia entre variables, se tiene que:

$$P(X|Z=1) = \prod_{k=1}^{K} m_k^{X_k}(1-m_k)^{1-X_k}$$

De manera análoga, el modelo de record linkage introduce otro conjunto de probabilidades que describen el comportamiento de las variables cuando los registros pertenecen a personas distintas. Estas probabilidades se definen como:

$$u_k = P(X_k = 1|Z=0)$$

Los cuales son probabilidades que representan coincidencias por azar, dado que el par no corresponde a la misma entidad. Por ejemplo:

1. Incluso cuando dos registros corresponden a personas diferentes, puede ocurrir que tengan el mismo nombre. Esto sucede porque muchos nombres son relativamente comunes. En este contexto, podríamos tener $u_{nombre} = 0.05$. Esto significa que aproximadamente un 5% de los pares de personas distintas podrían coincidir en el nombre. Aunque si la base de datos incluye nombres muy comunes, este valor de podría ser relativamente alto.
2. Los apellidos suelen ser más informativos que los nombres, especialmente en poblaciones donde la diversidad de apellidos es mayor. Sin embargo, todavía pueden existir coincidencias por azar (múltiples personas con apellido "García"); por tanto podríamos tener $u_{apellido} = 0.02$. Esto indica que alrededor del 2% de los pares de personas distintas coincidirían en el apellido.
3. La fecha de nacimiento suele ser una variable muy discriminante. La probabilidad de que dos personas distintas compartan exactamente la misma fecha de nacimiento es relativamente baja, especialmente si se considera día, mes y año completos. Por ejemplo, podríamos tener $u_{fecha} = 0.01$. Esto significa que solo en aproximadamente el 1% de los pares de personas diferentes se observaría coincidencia exacta en la fecha de nacimiento.

Variable	u_k
nombre	0.05
apellido	0.02
fecha nacimiento	0.01

Una vez más, asumiendo independencia entre variables, se tiene que:

$$P(X|Z=0) = \prod_{k=1}^{K} u_k^{X_k}(1-u_k)^{1-X_k}$$

La razón de verosimilitudes como regla decisión

Desde un punto de vista frecuentista, el estadístico central del modelo de Fellegi-Sunter es la razón de verosimilitudes, dada por la siguiente expresión

$$\Lambda(X) = \frac{P(X \mid Z=1)}{P(X \mid Z=0)} = \frac{\prod_{k=1}^{K} m_k^{X_k}(1-m_k)^{1-X_k}}{\prod_{k=1}^{K} u_k^{X_k}(1-u_k)^{1-X_k}}$$

Es posible demostrar que la regla de decisión óptima consiste en clasificar los pares utilizando este estadístico. Nótese que cuando se comparan varias variables, es posible que las productorias en $P(X \mid Z=1)$ y $P(X \mid Z=0)$ se acerquen a cero, y que se tengan problemas de numéricos de convergencia computacional (underflow). Por esta razón, es usual trabajar en escala logarítmica, Si sustituimos las expresiones anteriores, se obtiene nuevamente un producto de términos asociados a cada variable de comparación. Sin embargo, resulta más conveniente trabajar en escala logarítmica, ya que el logaritmo transforma las productorias en sumatorias, evitando problemas de magnitud computacional. En efecto, acudiendo a las reglas del logaritmo, y después de un poco de álgebra, se tiene que

$$\log \Lambda(X) = \sum_{k=1}^{K} \left[X_k \log\left(\frac{m_k}{u_k}\right) + (1-X_k)\log\left(\frac{1-m_k}{1-u_k}\right)\right].$$

De esta forma, la evidencia aportada por cada variable puede interpretarse como un peso, y el estadístico total se obtiene simplemente sumando los pesos asociados a los acuerdos y desacuerdos observados. En particular, para cada variable k se definen los pesos:

$$w_k^{(Z=1)} = \log\left(\frac{m_k}{u_k}\right)$$
$$w_k^{(Z=0)} = \log\left(\frac{1-m_k}{1-u_k}\right)$$

De esta manera, cada variable de comparación aporta una cierta cantidad de evidencia a favor o en contra de que el par de registros corresponda a la misma entidad. Esta evidencia se resume mediante los pesos definidos anteriormente. Al combinar la información proveniente de todas las variables consideradas, se obtiene un peso total que sintetiza la evidencia global del par, el cual se expresa como

$$W(X) = \sum_{k=1}^{K} w_k.$$

Este estadístico resume la información contenida en el vector de comparaciones X y permite ordenar los pares de registros de acuerdo con la evidencia de que correspondan a la misma entidad. Valores altos de $W(X)$ indican una mayor probabilidad de que el par sea un match, mientras que valores bajos sugieren que se trata de registros correspondientes a entidades distintas.

A partir de este estadístico, el modelo de Fellegi–Sunter propone una regla de decisión basada en dos umbrales. En particular, se definen dos valores T_U y T_M que permiten clasificar los pares de registros en tres posibles categorías: matches, non-matches o pares que requieren revisión manual. Formalmente, la regla de decisión se expresa como

$$\begin{cases} W(X) \geq T_M & \text{clasificar como match} \\ W(X) \leq T_U & \text{clasificar como non-match} \\ T_U < W(X) < T_M & \text{revisión clerical} \end{cases}$$

La presencia de una región intermedia responde al hecho de que, en algunos casos, la evidencia disponible no es suficientemente concluyente para tomar una decisión automática. En esas situaciones, el modelo recomienda que los pares sean evaluados mediante una revisión manual. Finalmente, los valores de los umbrales se determinan de modo que se controlen explícitamente las probabilidades de error del procedimiento de clasificación. En particular, el modelo considera dos tipos de error:

- **Error tipo I:** clasificar un *non-match* como *match*.
- **Error tipo II:** clasificar un *match* como *non-match*.

La elección de los umbrales T_U y T_M permite equilibrar estos errores y establecer un compromiso entre la tasa de clasificaciones automáticas y la necesidad de revisión manual de los pares ambiguos.

Probabilidad posterior de emparejamiento

El objetivo del modelo es calcular la probabilidad de que el par sea un match dado el patrón observado de coincidencias en la variables de comparación. Esto se expresa como

$$P(Z = 1 \mid X)$$

Y se conoce como la probabilidad posterior de match. Su interpretación es sencilla: dado el patrón de coincidencias entre los registros, $P(Z = 1 \mid X)$ representa la probabilidad de que correspondan a la misma persona. Para calcular esta probabilidad es necesario recurrir a la regla de Bayes, la cual establece que:

$$P(Z = 1|X) = \frac{P(X|Z = 1)P(Z = 1)}{P(X)}$$

En donde $P(Z = 1)$ es la probabilidad previa de emparejamiento, que representa la probabilidad de que un par de registros sea un match antes de observar las variables de comparación. Esta cantidad suele ser pequeña porque la mayoría de los pares posibles corresponden a personas diferentes. Además, $P(X)$, la probabilidad marginal del patrón, representa la probabilidad total de observar el patrón de coincidencias X, que, acudiendo al teorema de probabilidad total, se escribe de la siguiente manera:

$$P(X) = P(X|Z = 1)P(Z = 1) + P(X|Z = 0)P(Z = 0)$$

En donde

$$P(Z = 0) = 1 - P(Z = 1)$$

Por ende, notando que $\pi = P(Z = 1)$, y sustituyendo la expresión de $P(X)$ en el teorema de Bayes, se obtiene:

$$P(Z = 1|X) = \frac{\pi P(X|Z = 1)}{\pi P(X|Z = 1) + (1 - \pi)P(X|Z = 0)}$$

Si el patrón observado es mucho más probable bajo el modelo de match, entonces $P(Z = 1|X)$ será cercano a 1; si el patrón es más probable bajo el modelo de no-match, la probabilidad posterior será cercana a 0. Este cálculo permite transformar el patrón de coincidencias entre registros en una probabilidad cuantitativa de que el par sea un match y corresponde a la base del modelo probabilístico de **Fellegi–Sunter** y de muchos algoritmos modernos de record linkage.

Ejemplo

Supongamos que tenemos dos listas, como se describe a continuación:

idA	nombre	apellido	fecha_nac
A1	Juan	Pérez	1990-05-10
A2	María	Gómez	1988-11-03

idB	nombre	apellido	fecha_nac
B1	Juan	Pérez	1990-05-10
B2	María	Gómez	1987-11-03
B3	Carlos	López	1992-07-21

El primer paso es construir **todos los pares posibles** entre las dos listas. Como la lista A tiene 2 registros y la lista B tiene 3 registros, entonces el número total de pares es $2 \times 3 = 6$ y la tabla de todos los posibles pares es:

idA	idB	nombre_A	nombre_B	apellido_A	apellido_B	fnac_A	fnac_B
A1	B1	Juan	Juan	Pérez	Pérez	1990-05-10	1990-05-10
A1	B2	Juan	María	Pérez	Gómez	1990-05-10	1987-11-03
A1	B3	Juan	Carlos	Pérez	López	1990-05-10	1992-07-21
A2	B1	María	Juan	Gómez	Pérez	1988-11-03	1990-05-10
A2	B2	María	María	Gómez	Gómez	1988-11-03	1987-11-03
A2	B3	María	Carlos	Gómez	López	1988-11-03	1992-07-21

En una segunda instancia, transformamos las variables originales en variables de comparación binarias para crear la matriz X, así:

idA	idB	nombre_match	apellido_match	fnac_match
A1	B1	1	1	1
A1	B2	0	0	0
A1	B3	0	0	0
A2	B1	0	0	0
A2	B2	1	1	0
A2	B3	0	0	0

De esta forma, cada par tiene un vector de comparación

$$X_i = (x_{i1}, x_{i2}, x_{i3})$$

Además, supongamos que la probabilidad a priori de que un par de registros corresponda a la misma entidad es $\pi = 0.2$ y que se cuenta con los siguientes valores para los parámetros del modelo de emparejamiento, que representan las probabilidades de acuerdo entre variables cuando los registros sí corresponden a la misma entidad (m_k) y cuando no corresponden a la misma entidad (u_k)::

Variable	m_k	u_k
nombre	0.9	0.1
apellido	0.9	0.1
fecha nacimiento	0.8	0.05

Consideremos ahora el par A2–B2. Para este par se observa el vector de comparaciones $X_2 = (1, 1, 0)$, lo que significa que coinciden el nombre y el apellido, pero no coincide la fecha de nacimiento. A partir de los parámetros del modelo, es posible calcular la probabilidad de observar ese patrón de coincidencias bajo cada uno de los dos posibles estados: que los registros correspondan a la misma entidad ($Z = 1$) o que correspondan a entidades distintas ($Z = 0$).

Asimismo, los pesos de Fellegi–Sunter son los siguientes:

Variable	m_k	u_k	Peso acuerdo $w_k^{(1)}$	Peso desacuerdo $w_k^{(0)}$
nombre	0.9	0.1	$\log(9) = 2.197$	$\log(0.111) = -2.197$
apellido	0.9	0.1	$\log(9) = 2.197$	$\log(0.111) = -2.197$
fecha nacimiento	0.8	0.05	$\log(16) = 2.773$	$\log(0.2105) = -1.558$

Por ende, para el par A2–B2, cuyo vector de comparación es $X_2 = (1, 1, 0)$, el peso total sería

$$W(X_2) = 2.197 + 2.197 - 1.558 = 2.836$$

Y para todos los pares, tendríamos la siguiente tabla con su interpretación.

Par	Vector X	Peso $W(X)$	Interpretación
A1–B1	(1,1,1)	7.167	match casi seguro
A1–B2	(0,0,0)	-5.952	no match
A1–B3	(0,0,0)	-5.952	no match
A2–B1	(0,0,0)	-5.952	no match
A2–B2	(1,1,0)	**2.836**	match probable
A2–B3	(0,0,0)	-5.952	no match

Ahora, desde un punto de vista probabilístico, también se obtienen las mismas conslusiones. En efecto, para el par A2-B2, se obtiene que:

- $P(X_2|Z = 1) = m_1 \times m_2 \times (1 - m_3) = 0.9 \times 0.9 \times 0.2 = 0.162$
- $P(X_2|Z = 0) = u_1 \times u_2 \times (1 - u_3) = 0.1 \times 0.1 \times 0.95 = 0.0095$.

Una vez calculadas estas probabilidades, se puede aplicar la ecuación de la probabilidad posterior de match, que combina la evidencia observada en el vector de comparación con la probabilidad a priori π:

$$P(Z = 1 \mid X_2) = \frac{\pi P(X_2 \mid Z = 1)}{\pi P(X_2 \mid Z = 1) + (1 - \pi) P(X_2 \mid Z = 0)} = \frac{0.2 \times 0.162}{0.2 \times 0.162 + 0.8 \times 0.0095} = 0.81$$

Es decir, la probabilidad de que este par de registros corresponda a la misma entidad es 0.81, lo que sugiere que se trata de un emparejamiento bastante plausible. De manera análoga, si se realiza este mismo cálculo para todos los posibles pares de registros entre las dos bases de datos, se obtiene la siguiente tabla de probabilidades de match:

Par	Vector X	Probabilidad de match
A1–B1	(1,1,1)	**0.997**
A1–B2	(0,0,0)	0.00065
A1–B3	(0,0,0)	0.00065

Par	Vector X	Probabilidad de match
A2–B1	(0,0,0)	0.00065
A2–B2	(1,1,0)	**0.81**
A2–B3	(0,0,0)	0.00065

A partir de estos resultados, se observa que el modelo está identificando dos pares con probabilidades sustanciales de corresponder a la misma entidad: el par A1–B1 (match casi seguro) y el par A2–B2 (match probable). En contraste, los demás pares presentan probabilidades muy bajas, lo que indica que es muy poco probable que correspondan a la misma persona.

En la práctica, los algoritmos modernos aplican exactamente esta misma lógica, pero sobre millones de pares de registros, utilizando múltiples variables de comparación y técnicas computacionales que permiten realizar estos cálculos de manera eficiente.

Inferencia bayesiana

La inferencia bayesiana constituye un marco general para realizar inferencia estadística a partir de datos observados y conocimiento previo sobre los parámetros de interés. El punto de partida es la especificación de la verosimilitud del modelo, es decir, la distribución de probabilidad que describe cómo se generan los datos en función de un conjunto de parámetros desconocidos. Esta verosimilitud resume el mecanismo probabilístico que conecta el modelo con la información empírica disponible y representa la contribución de los datos al proceso de inferencia.

Una vez definida la verosimilitud, se deben establecer distribuciones previas para los parámetros del modelo, las cuales reflejan el conocimiento o las creencias existentes antes de observar los datos. La combinación de la verosimilitud con estas distribuciones previas, mediante el teorema de Bayes, permite obtener la distribución posterior, que representa la distribución de probabilidad de los parámetros condicionada a los datos observados. En muchos modelos de interés la distribución posterior no puede obtenerse de forma analítica, por lo que se recurre a métodos computacionales, como los algoritmos de simulación tipo Markov Chain Monte Carlo (MCMC), para aproximarla y realizar inferencias sobre los parámetros del modelo.

Verosimilitud del modelo

Sea Z_i_la variable latente que indica si el par i corresponde a un *match* o a un *non-match*. En el modelo se asume que esta variable sigue una distribución Bernoulli con probabilidad π de que el par corresponda a la misma persona:

$$Z_i \sim \text{Bernoulli}(\pi)$$

Condicionalmente al estado de Z_i, se modela el comportamiento de las variables de comparación. En particular, cada componente del vector de comparaciones se modela mediante una distribución Bernoulli. Para el caso en que el par corresponde a la misma persona ($Z_i = 1$), se tiene que

$$X_{ik}|Z = 1 \sim Bernoulli(m_k)$$

donde el parámetro $m_k = P(X_k = 1|Z = 1)$ representa la probabilidad de acuerdo en el campo k cuando los registros corresponden al mismo individuo. De forma análoga, cuando los registros no corresponden a la misma persona ($Z_i = 0$), se define un modelo similar pero con un parámetro diferente que captura la probabilidad de acuerdo entre registros distintos:

$$X_{ik}|Z = 0 \sim Bernoulli(u_k)$$

donde $u_k = P(X_k = 1|Z = 0)$. Este parámetro representa la probabilidad de acuerdo en el campo k cuando el par corresponde a registros de personas diferentes.

Bajo el supuesto de independencia condicional entre las variables de comparación dado el estado de Z_i, la distribución conjunta del vector de comparaciones puede expresarse como el producto de las distribuciones de cada componente. En consecuencia, las distribuciones condicionales del vector X_i vienen dadas por

$$P(X_i \mid Z_i = 1) = \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 1) = \prod_{k=1}^{K} m_k^{X_{ik}} (1 - m_k)^{1-X_{ik}}$$

$$P(X_i \mid Z_i = 0) = \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 0) = \prod_{k=1}^{K} u_k^{X_{ik}} (1 - u_k)^{1-X_{ik}}.$$

A partir de estas distribuciones condicionales es posible obtener la distribución marginal del vector de comparaciones. Para ello se aplica el teorema de probabilidad total, considerando los dos posibles estados de la variable latente Z_i. De esta forma, la distribución marginal de X_i se expresa como

$$\begin{aligned} P(X_i) &= \pi P(X_i \mid Z_i = 1) + (1 - \pi) P(X_i \mid Z_i = 0) \\ &= \pi \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 1) + (1 - \pi) \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 0) \end{aligned}$$

Si se observan N pares de registros independientes, la verosimilitud del modelo se obtiene como el producto de las probabilidades marginales de cada vector de comparaciones observado. En consecuencia, la función de verosimilitud puede escribirse como

$$\begin{aligned} P(X|m, u, \pi) &= \prod_{i=1}^{N} P(X_i) \\ &= \prod_{i=1}^{N} \left[\pi \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 1) + (1 - \pi) \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 0) \right] \end{aligned}$$

Para facilitar la estimación del modelo, resulta conveniente trabajar en escala logarítmica, ya que esto permite transformar productos en sumas y simplificar los cálculos. Aplicando propiedades matemáticas, se tiene que

$$\begin{aligned} \log P(X|m, u, \pi) &= \sum_{i=1}^{N} \log \left[\pi \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 1) + (1 - \pi) \prod_{k=1}^{K} P(X_{ik} \mid Z_i = 0) \right] \\ &= \sum_{i=1}^{N} \log \left[\exp \left(\log \pi + \sum_{k=1}^{K} \log P(X_{ik} \mid Z_i = 1) \right) \right. \\ &\qquad \left. + \exp \left(\log(1 - \pi) + \sum_{k=1}^{K} \log P(X_{ik} \mid Z_i = 0) \right) \right] \end{aligned}$$

Esta última expresión corresponde precisamente al tipo de funciones que se utilizan en la implementación computacional del modelo. En particular, la estructura $\log [\exp(\cdot) + \exp(\cdot)]$ es evaluada mediante transformaciones numéricamente estables. Este tipo de cálculos es el que emplea el software de inferencia bayesiana STAN, el cual implementa funciones especializadas para evaluar expresiones de este tipo evitando problemas de precisión numérica y permitiendo estimar eficientemente los parámetros del modelo.

Distribuciones previas

En un enfoque completamente bayesiano, la incertidumbre acerca de la localización de los parámetros que gobiernan el modelo probabilístico se trata como una variable aleatoria y por tanto se asignan distribuciones previas a cada uno de ellos. En el modelo de Fellegi–Sunter, los parámetros principales son m_k, la probabilidad de acuerdo entre registros verdaderamente coincidentes; u_k, la probabilidad de acuerdo entre registros que no corresponden a la misma entidad; π, la proporción de pares que corresponden a verdaderas coincidencias en el conjunto de comparaciones.

Una elección natural para estos parámetros son distribuciones Beta, ya que se trata de probabilidades definidas en $[0, 1]$. De esta forma:

$$m_k \sim Beta(a_m, b_m)$$

$$u_k \sim Beta(a_u, b_u)$$

$$\pi \sim Beta(a_\pi, b_\pi)$$

Estas distribuciones previas permiten incorporar conocimiento previo sobre la calidad de las variables de comparación, estimar la incertidumbre en los parámetros y obtener la distribución posterior completa mediante métodos computacionales como MCMC. La siguiente tabla muestra algunas distribuciones previas que podrían usarse, dependiendo de la situación en la que estemos.

Parámetro	Distribución sugerida	Interpretación
m_k	$Beta(9, 1)$	Variable altamente discriminante, alta probabilidad de acuerdo en verdaderos matches.
m_k	$Beta(5, 2)$	Variable moderadamente confiable, algo de incertidumbre en la coincidencia.
u_k	$Beta(1, 9)$	Probabilidad baja de acuerdo en pares no coincidentes.
u_k	$Beta(2, 8)$	Variable con mayor posibilidad de coincidencias aleatorias.
π	$Beta(2, 8)$	Baja proporción de verdaderos matches en el conjunto de pares.
π	$Beta(5, 5)$	Prior poco informativa, refleja incertidumbre sobre la proporción de matches.

Distribución Posterior

Una vez definidas la verosimilitud del modelo y las distribuciones previas de los parámetros, la inferencia bayesiana se centra en la distribución posterior, que combina la información de los datos con el conocimiento previo. Formalmente, al asumir independencia entre los parámetros, la distribución posterior se obtiene aplicando la regla de Bayes, de la siguiente forma:

$$P(m, u, \pi \mid X) \propto P(X \mid m, u, \pi) \cdot P(m) \cdot P(u) \cdot P(\pi)$$

donde $P(X \mid m, u, \pi)$ es la verosimilitud de los datos observados y $P(m)$, $P(u)$, $P(\pi)$ son las distribuciones previas de los parámetros. La distribución posterior refleja nuestra incertidumbre actualizada sobre

los parámetros del modelo después de observar los datos. A diferencia de un estimador puntual, esta distribución posterior proporciona un marco completo para cuantificar la incertidumbre, permitiendo calcular intervalos de credibilidad, probabilidades de que los parámetros superen ciertos umbrales, o directamente las probabilidades de que cada par de registros sea un match verdadero.

En la práctica, la posterior raramente se puede obtener de manera analítica debido a la complejidad del modelo y la multiplicidad de variables de comparación. Por ello, se recurre a métodos computacionales, como algoritmos de simulación tipo Markov Chain Monte Carlo (MCMC), para generar muestras de la posterior. Estas muestras permiten realizar inferencia sobre los parámetros y sobre los pares de registros, calcular probabilidades posteriores de coincidencia, y tomar decisiones basadas en un marco probabilístico sólido y coherente.

Implementación bayesiana paso a paso

En este capítulo se describe el archivo `FellegiSunter.r` en bloques lógicos para mostrar qué hace cada parte del código y por qué es necesaria dentro de un flujo simple de *record linkage* bayesiano.

En conjunto, `RecordLinkage.r` sigue una secuencia lógica que va desde la preparación de los datos hasta la comparación de métodos de inferencia. El script comienza limpiando el entorno de trabajo y cargando las librerías necesarias, luego simula dos archivos con coincidencias verdaderas conocidas y genera todos los pares posibles entre ellos. A partir de estos pares, construye variables binarias de comparación y conserva la "verdad" simulada, lo que permite evaluar posteriormente el desempeño de los métodos.

En una siguiente etapa, se ejecuta `fastLink` como punto de referencia y, en paralelo, se especifica un modelo bayesiano de Fellegi-Sunter en STAN, el cual se ajusta mediante MCMC. Con los resultados del modelo, se calculan las probabilidades posteriores de *match* para cada par y finalmente se comparan los resultados obtenidos por ambos enfoques.

De esta forma, el archivo no solo implementa un ejemplo práctico de *record linkage*, sino que también articula claramente tres niveles de análisis: la simulación de datos, la formulación probabilística del problema y la implementación computacional de la inferencia bayesiana.

Carga de librerías y configuración inicial

El script comienza limpiando el entorno de trabajo, cargando las librerías necesarias y definiendo algunas opciones para que STAN pueda compilar y ejecutar el modelo de manera más eficiente.

```r
rm(list = ls())

library(rstan)
library(fastLink)
library(tidyverse)

rstan_options(auto_write = TRUE)
options(mc.cores = parallel::detectCores())

set.seed(123)
```

El código comienza limpiando el entorno de trabajo mediante la función `rm(list = ls())`, lo que elimina todos los objetos existentes en memoria y evita que resultados previos interfieran con la ejecución actual. A continuación, se cargan las librerías necesarias: `library(rstan)` permite utilizar STAN desde R para ajustar modelos bayesianos, mientras que `library(fastLink)` incorpora una implementación ya existente de record linkage, lo que resulta útil para comparar su desempeño con el modelo que se desarrollará en STAN.

Posteriormente, se configuran algunas opciones clave para mejorar la eficiencia y reproducibilidad del análisis. La instrucción `rstan_options(auto_write = TRUE)` permite reutilizar archivos compilados por STAN, reduciendo significativamente los tiempos de ejecución en corridas posteriores. Por su parte, `options(mc.cores = parallel::detectCores())` habilita el uso de todos los núcleos disponibles del procesador, lo que facilita la ejecución paralela de múltiples cadenas MCMC. Finalmente, `set.seed(123)` fija la semilla aleatoria, garantizando que los resultados obtenidos puedan reproducirse exactamente en futuras ejecuciones.

Construcción de los listados que serán emparejados

Luego se generan dos listas de registros. La base `A` representa un primer archivo y la base `B` un segundo archivo. Una parte de `B` se construye para que contenga coincidencias reales con `A`, mientras que otra parte agrega registros extra que no necesariamente tienen correspondencia. Es decir, se construye un conjunto de datos sintético que simula dos bases de información a ser vinculadas. Primero se define el tamaño de ambas listas, donde `A` contiene 50 registros y `B` contiene 60. Luego se crean catálogos simples de nombres, apellidos y sexo, los cuales sirven como insumos para generar variables de identificación. A partir de estos catálogos, se construye la base `A` como un conjunto de datos sintético que incluye un identificador único, nombre, apellido, edad y sexo para cada individuo.

A continuación, se introduce un mecanismo controlado de coincidencias reales entre ambas bases. Se define que los primeros 30 registros de `B` corresponden verdaderamente a los primeros 30 registros de `A`. Para ello:

1. Se construye `B_match` copiando esos registros, pero incorporando una pequeña perturbación en la variable edad de -1, 0 o 1, con el fin de imitar errores o variaciones típicas entre fuentes de datos.
2. Luego se genera `B_extra` con registros adicionales independientes que no tienen correspondencia en `A`, y finalmente se concatenan ambas partes para formar la base final `B`.

En esencia, este procedimiento crea un escenario controlado en el que se conoce la verdad subyacente, lo que resulta especialmente útil para evaluar si el método de record linkage es capaz de recuperar correctamente las coincidencias reales.

```r
nA <- 50
nB <- 60

nombres <- c("Juan","Maria","Pedro","Ana","Luis","Carlos",
             "Lucia","Jorge","Sofia","Miguel","Laura")

apellidos <- c("Gomez","Perez","Rodriguez","Lopez","Garcia")

sexos <- c("M","F")

A <- data.frame(
  idA = 1:nA,
  nombre = sample(nombres,nA,replace=TRUE),
  apellido = sample(apellidos,nA,replace=TRUE),
  edad = sample(20:60,nA,replace=TRUE),
  sexo = sample(sexos,nA,replace=TRUE)
)

n_match_true <- 30

B_match <- data.frame(
  idB = 1:n_match_true,
```

```r
  nombre = A$nombre[1:n_match_true],
  apellido = A$apellido[1:n_match_true],
  edad = A$edad[1:n_match_true] + sample(c(-1,0,1),n_match_true,replace=TRUE),
  sexo = A$sexo[1:n_match_true]
)

B_extra <- data.frame(
  idB = (n_match_true+1):nB,
  nombre = sample(nombres,nB-n_match_true,replace=TRUE),
  apellido = sample(apellidos,nB-n_match_true,replace=TRUE),
  edad = sample(20:60,nB-n_match_true,replace=TRUE),
  sexo = sample(sexos,nB-n_match_true,replace=TRUE)
)

B <- rbind(B_match,B_extra)
```

A continuación se muestran los primeros seis registros de ambos listados.

```r
head(A)
```

```
##   idA nombre apellido edad sexo
## 1   1  Pedro    Gomez   38    M
## 2   2  Pedro   Garcia   44    F
## 3   3 Miguel    Gomez   58    M
## 4   4  Maria    Perez   45    F
## 5   5 Carlos    Lopez   28    M
## 6   6  Laura    Lopez   26    M
```

```r
head(B)
```

```
##   idB nombre apellido edad sexo
## 1   1  Pedro    Gomez   37    M
## 2   2  Pedro   Garcia   44    F
## 3   3 Miguel    Gomez   58    M
## 4   4  Maria    Perez   45    F
## 5   5 Carlos    Lopez   29    M
## 6   6  Laura    Lopez   25    M
```

Generación de todos los pares posibles

Una vez construidas las dos bases, el siguiente paso es formar el producto cartesiano entre `A` y `B`, es decir, todos los pares candidato que podrían compararse.

```r
pairs <- merge(A,B,by=NULL)
N <- nrow(pairs)
```

La instrucción `merge(A, B, by = NULL)` genera todos los pares posibles entre los registros de `A` y los registros de `B`, es decir, construye el producto cartesiano entre ambos conjuntos de datos. Como `A` tiene 50 filas y `B` tiene 60, entonces el número total de pares generados será 50 x 60 = 3000. A partir de este resultado, la expresión `N <- nrow(pairs)` permite almacenar ese total de pares, el cual será una de las entradas clave del modelo en STAN.

Este paso es fundamental porque transforma el problema original de enlazar dos archivos en un problema de clasificación de pares: cada combinación posible de registros debe ser evaluada y clasificada como un posible match o non-match. A continuación se observan lo primeros registros de la tabla de datos que contiene los pares de comparación.

```r
head(pairs)
```

```
##   idA nombre.x apellido.x edad.x sexo.x idB
## 1   1    Pedro      Gomez     38      M   1
## 2   2    Pedro     Garcia     44      F   1
## 3   3   Miguel      Gomez     58      M   1
## 4   4    Maria      Perez     45      F   1
## 5   5   Carlos      Lopez     28      M   1
## 6   6    Laura      Lopez     26      M   1
##   nombre.y apellido.y edad.y sexo.y
## 1    Pedro      Gomez     37      M
## 2    Pedro      Gomez     37      M
## 3    Pedro      Gomez     37      M
## 4    Pedro      Gomez     37      M
## 5    Pedro      Gomez     37      M
## 6    Pedro      Gomez     37      M
```

Construcción de las variables de comparación

Después de formar todos los pares, el código compara campo por campo para resumir el nivel de acuerdo entre los registros. Estas comparaciones son justamente las variables que alimentan el modelo de Fellegi-Sunter.

En esta etapa se construyen cuatro indicadores binarios que resumen la comparación entre registros: `nombre_match`, que toma el valor 1 si los nombres coinciden exactamente; `apellido_match`, que vale 1 cuando los apellidos coinciden; `edad_match`, que es 1 si las edades difieren a lo sumo en una unidad; y `sexo_match`, que toma el valor 1 cuando el sexo coincide. Estos indicadores permiten traducir las comparaciones entre variables en una forma numérica sencilla y homogénea.

Posteriormente, estas variables se organizan en una matriz `X`, donde cada fila corresponde a un par de registros y cada columna representa una de las variables de comparación. Además, se define `K` como el número total de variables de comparación, que en este caso es 4. Esta matriz `X` constituye el insumo central del modelo bayesiano, ya que cada fila resume la evidencia observada a favor o en contra de que un par de registros corresponda a una misma unidad (match) o no (non-match).

A continuación se observan lo primeros registros de la matriz de comparación.

```r
head(X)
```

```
##      nombre_match apellido_match edad_match
## [1,]            1              1          1
## [2,]            1              0          0
## [3,]            0              1          0
## [4,]            0              0          0
## [5,]            0              0          0
## [6,]            0              0          0
##      sexo_match
## [1,]          1
## [2,]          0
## [3,]          1
```

```
## [4,]          0
## [5,]          1
## [6,]          1
```

Definición de las entidades emparejadas

En este paso se construye una variable que identifica cuáles pares son verdaderamente coincidencias. Esta variable no se usa para ajustar el modelo bayesiano. Su función es servir como referencia para evaluar el desempeño del método una vez que se haya estimado.

```
pairs$true_match <- ifelse(
  pairs$idA <= n_match_true &
    pairs$idB == pairs$idA,
  1,0)
```

Se asigna el valor 1 a aquellos pares que cumplen simultáneamente dos condiciones: por un lado, que `idA` se encuentre entre los primeros 30 registros que corresponden a coincidencias reales, y por otro, que `idB == idA`, lo cual refleja la forma específica en que se construyó la correspondencia entre `A` y `B_match`.

Todos los demás pares que no satisfacen estas condiciones se marcan con 0, de modo que esta variable indica de manera clara cuáles pares corresponden a coincidencias verdaderas y cuáles no.

Aplicación de `fastLink`

Antes de ajustar el modelo en STAN, el script ejecuta el paquete `fastLink` como punto de comparación.

En primer lugar, es necesario asegurar que cada variable sea interpretada correctamente por el algoritmo. Luego se ejecuta `fastLink()` especificando las variables que se emplearán para enlazar ambos archivos, indicando explícitamente que `nombre` y `apellido` deben tratarse como campos de texto, mientras que `edad` se maneja como una variable numérica. A partir de esta ejecución, se extraen los pares identificados como coincidencias por el algoritmo y se almacenan en el objeto `matches_fastlink`.

```
head(matches_fastlink)
```

```
##   idA idB
## 1   1   1
## 2   2   2
## 3   3   3
## 4   4   4
## 5   5   5
## 6   6   6
```

En el contexto del script, este bloque es clave porque permite contrastar dos enfoques distintos: por un lado, el uso de un método ya implementado en un paquete especializado, y por otro, una implementación explícita del modelo bayesiano en STAN.

Modelo Fellegi-Sunter bayesiano en Stan

El núcleo conceptual del script aparece cuando se define el modelo probabilístico en lenguaje STAN. Este bloque traduce la idea del modelo de Fellegi-Sunter a una formulación que puede estimarse por MCMC.

```
stan_code <- "
data {

  int<lower=1> N;                // numero de pares
  int<lower=1> K;                // numero de variables de comparacion
  int<lower=0,upper=1> X[N,K];  // matriz de acuerdos

}

parameters {

  vector<lower=0,upper=1>[K] m;   // probabilidad de acuerdo dado match
  vector<lower=0,upper=1>[K] u;   // probabilidad de acuerdo dado no-match
  real<lower=0,upper=1> pi;       // proporcion de matches

}

model {
  // Verosimilitud

  real log_m;
  real log_u;

  for(i in 1:N){

    log_m = 0;
    log_u = 0;

    for(k in 1:K){

      log_m += bernoulli_lpmf(X[i,k] | m[k]);
      log_u += bernoulli_lpmf(X[i,k] | u[k]);

    }

    target += log_sum_exp(
                log(pi) + log_m,
                log1m(pi) + log_u
              );

  }

  // Distribuciones previas

  m ~ beta(8,2);
  u ~ beta(2,8);
  pi ~ beta(1,5);

}

generated quantities {

  vector[N] p_match;
```

```
  for(i in 1:N){

    real log_m;
    real log_u;

    log_m = log(pi);
    log_u = log1m(pi);

    for(k in 1:K){
      log_m += bernoulli_lpmf(X[i,k] | m[k]);
      log_u += bernoulli_lpmf(X[i,k] | u[k]);
    }

    p_match[i] = exp(log_m) / (exp(log_m) + exp(log_u));

  }

}

"
```

En el bloque `data` se declaran los insumos del modelo: `N`, que corresponde al número total de pares generados; `K`, que indica el número de variables de comparación; y `X[N,K]`, que es la matriz binaria que resume los acuerdos entre registros para cada par. Esta matriz constituye la evidencia observada que alimenta el modelo.

En la sección `parameters` aparecen los parámetros clásicos del modelo de Fellegi-Sunter. Por un lado, `m[k]` representa la probabilidad de acuerdo en la variable `k` cuando el par es un *match*, mientras que `u[k]` corresponde a la probabilidad de acuerdo cuando el par es un *non-match*. Adicionalmente, `pi` modela la proporción global de pares que efectivamente son coincidencias verdaderas dentro del conjunto total.

Asimismo, en la verosimilitud marginal, para cada par `i` el código calcula `log_m`, que es la log-probabilidad del patrón observado bajo la hipótesis de que el par es un *match*, y `log_u`, que corresponde a la hipótesis de *non-match*. Luego, mediante `log_sum_exp`, se suma a `target` la contribución marginal del par, lo que implementa de forma numéricamente estable la combinación ponderada por `pi` de ambas posibilidades. En otras palabras, STAN no observa directamente si un par es o no un *match*, sino que integra esa incertidumbre al evaluar la probabilidad de los datos observados.

El modelo se completa con la especificación de distribuciones previas: se asume `m ~ beta(8,2)`, lo que favorece probabilidades altas de acuerdo en verdaderos *matches*; `u ~ beta(2,8)`, que favorece acuerdos bajos en *non-matches*; y `pi ~ beta(1,5)`, reflejando que las coincidencias reales suelen ser poco frecuentes entre todos los pares posibles. Estas elecciones incorporan conocimiento previo razonable sobre el problema.

Finalmente, para cada par de registros se calcula la probabilidad posterior de que sea un *match*, utilizando los valores de los parámetros simulados en cada iteración del algoritmo MCMC. En otras palabras, toma los parámetros `m`, `u` y `pi` generados por STAN y, con ellos, evalúa qué tan probable es que cada par corresponda a una coincidencia real. Para cada par `i`, el código construye dos cantidades: `log_m`, que representa la log-probabilidad de observar el patrón de acuerdos `X[i, ]` si el par fuera un *match*, y `log_u`, que corresponde a la misma probabilidad bajo la hipótesis de *non-match*. Ambas comienzan incorporando la información previa a través de `pi` (la proporción de *matches*) y luego se van acumulando sumando las contribuciones de cada variable de comparación mediante la función de verosimilitud Bernoulli.

Adicionalmente, el código transforma estas cantidades desde la escala logarítmica a probabilidades y calcula, para cada par, la probabilidad posterior de ser un *match* como una razón entre ambas hipótesis. El resultado se almacena en el vector `p_match`, de modo que en cada iteración de STAN se obtiene una estimación probabilística completa para todos los pares, incorporando la incertidumbre de los parámetros del modelo.

Ajuste del modelo

Una vez especificado el modelo, el script prepara los datos en una lista y llama a STAN para estimar la distribución posterior de los parámetros.

El objeto `data_list` se encarga de empaquetar toda la información en el formato que STAN espera recibir como entrada, asegurando que los datos del modelo estén correctamente estructurados. Luego, la función `stan()` compila el modelo y ejecuta el proceso de simulación mediante MCMC, lo que permite aproximar la distribución posterior de los parámetros de interés.

En este contexto, `iter = 2000` define el número de iteraciones que se ejecutan en cada cadena, mientras que `chains = 4` indica que se corren cuatro cadenas independientes, lo cual es clave para evaluar la convergencia del algoritmo. Además, el argumento `seed = 123` garantiza la reproducibilidad de los resultados. Como salida, el objeto `fit` contiene las muestras posteriores de los parámetros `m`, `u` y `pi`, que son fundamentales para el análisis del modelo.

Cálculo de la probabilidad posterior de *match*

Después del ajuste, el script extrae los parámetros estimados y calcula, para cada par, una probabilidad posterior de coincidencia.

```
post <- rstan::extract(fit)

m_hat <- colMeans(post$m)
u_hat <- colMeans(post$u)
pi_hat <- mean(post$pi)
p_match <- colMeans(post$p_match)

pairs$p_match <- p_match
pairs$bayes_match <- ifelse(pairs$p_match > 0.5,1,0)

matches_bayes <- pairs[pairs$bayes_match==1,c("idA","idB")]
```

Este bloque de código toma las muestras posteriores generadas por STAN y construye estimaciones resumidas para los parámetros y las probabilidades de *match*. Primero, `rstan::extract(fit)` recupera las simulaciones MCMC almacenadas en `fit`. A partir de estas, se calculan estimaciones puntuales mediante promedios posteriores: `m_hat` y `u_hat` como las medias por columna de `post$m` y `post$u`, respectivamente, y `pi_hat` como la media de `post$pi`.

Luego, `p_match <- colMeans(post$p_match)` calcula, para cada par de registros, la probabilidad posterior promedio de ser un *match*, integrando la incertidumbre de los parámetros. Estas probabilidades se incorporan al data frame original `pairs` en la columna `p_match`, y se define una clasificación binaria `bayes_match` asignando 1 a los pares cuya probabilidad supera el umbral de 0.5.

Finalmente, `matches_bayes` extrae únicamente los pares clasificados como coincidencias (*matches*), conservando los identificadores `idA` e `idB`. De esta manera, el bloque traduce los resultados probabilísticos del modelo bayesiano en una decisión concreta de emparejamiento. Obsérvese que aquí se usa una decisión por umbral fijo de 0.5. En una aplicación real, ese umbral podría modificarse dependiendo del costo de falsos positivos y falsos negativos.

Comparación entre métodos

El script termina juntando los resultados de `fastLink` y del procedimiento bayesiano para compararlos en una misma tabla.

```r
matches_fastlink$fastlink <- 1
matches_bayes$bayes <- 1

comparison <- merge(
  matches_fastlink,
  matches_bayes,
  by=c("idA","idB"),
  all=TRUE
)

comparison$fastlink[is.na(comparison$fastlink)] <- 0
comparison
```

```
##    idA idB fastlink bayes
## 1    1   1        1     1
## 2    2   2        1     1
## 3    3   3        1     1
## 4    4   4        1     1
## 5    5   5        1     1
## 6    6   6        1     1
## 7    7   7        1     1
## 8    8   8        1     1
## 9    9   9        1     1
## 10  10  10        1     1
## 11  11  11        1     1
## 12  12  12        1     1
## 13  13  13        1     1
## 14  14  14        1     1
## 15  15  15        1     1
## 16  16  16        1     1
## 17  17  17        1     1
## 18  18  16        0     1
## 19  18  18        1     1
## 20  19  19        1     1
## 21  20  20        1     1
## 22  21  21        1     1
## 23  22  22        1     1
## 24  23  23        1     1
## 25  24  24        1     1
## 26  25  25        1     1
## 27  26  26        1     1
## 28  27  27        1     1
## 29  28  28        1     1
## 30  29  29        1     1
## 31  30  30        1     1
## 32  45  49        0     1
```

En este bloque se añaden indicadores que permiten identificar qué pares fueron detectados como coincidencias por cada uno de los métodos. Luego, ambas salidas se combinan utilizando `merge(..., all = TRUE)`, lo que asegura que se conserven tanto las coincidencias compartidas entre métodos como aquellas que son exclusivas de cada procedimiento. Tras esta unión, los valores faltantes en la columna correspondiente a `fastlink` se reemplazan por 0, indicando explícitamente que esos pares no fueron identificados por dicho método.

Aunque el script termina en este punto, el paso siguiente natural sería completar también la columna `bayes` asignando ceros a los valores faltantes. Con ambas salidas completamente definidas, es posible calcular distintas medidas de desempeño, como el número total de coincidencias detectadas por cada método, la cantidad de coincidencias en común y métricas como la precisión y la sensibilidad en relación con la variable `true_match`.

A continuación se muestran los primeros seis registros emparejados según el modelo bayesiano en la base de pares de comparación.

```
##   idA nombre.x apellido.x edad.x sexo.x idB
## 1   1    Pedro      Gomez     38      M   1
## 2   2    Pedro     Garcia     44      F   2
## 3   3   Miguel      Gomez     58      M   3
## 4   4    Maria      Perez     45      F   4
## 5   5   Carlos      Lopez     28      M   5
## 6   6    Laura      Lopez     26      M   6
##   nombre.y apellido.y edad.y sexo.y nombre_match
## 1    Pedro      Gomez     37      M            1
## 2    Pedro     Garcia     44      F            1
## 3   Miguel      Gomez     58      M            1
## 4    Maria      Perez     45      F            1
## 5   Carlos      Lopez     29      M            1
## 6    Laura      Lopez     25      M            1
##   apellido_match edad_match sexo_match
## 1              1          1          1
## 2              1          1          1
## 3              1          1          1
## 4              1          1          1
## 5              1          1          1
## 6              1          1          1
##   true_match            p_match bayes_match
## 1          1 0.9348257360474781           1
## 2          1 0.9348257360474781           1
## 3          1 0.9348257360474781           1
## 4          1 0.9348257360474781           1
## 5          1 0.9348257360474781           1
## 6          1 0.9348257360474781           1
```

Record Linkage con Errores de Medición

El problema de *record linkage* consiste en determinar si dos registros provenientes de diferentes fuentes corresponden a la misma entidad. Recordemos que $Z \in \{0, 1\}$ es una variable latente tal que:

$$Z = \begin{cases} 1 & \text{si el par corresponde a la misma entidad (match)} \\ 0 & \text{si el par corresponde a distintas entidades (no match)} \end{cases}$$

con $P(Z = 1) = \pi$. Además, para cada variable $k = 1, \ldots, K$, se define una variable observable de comparación entre registros de ambas listas:

$$X_k = \begin{cases} 1 & \text{si hay acuerdo entre los registros} \\ 0 & \text{si hay desacuerdo} \end{cases}$$

El objetivo es derivar la razón de verosimilitudes $P(X \mid Z = 1)/P(X \mid Z = 0)$ a partir de un modelo generativo con errores de medición.

Modelo de Copas-Hilton (1990)

En esta formulación, el modelo clásico de record linkage se obtiene como una marginalización de un modelo generativo con errores de medición. En este escenario, los parámetros m_k y u_k no son primitivos, sino funciones de la calidad de medición y la distribución del error en las variables consideradas.

Sea Y_k el valor verdadero (latente) de la variable k, el cual no se observa directamente, y cuya distribución poblacional está dada por

$$P(Y_k = y) = f_k(y),$$

En donde $f_k(\cdot)$ describe la distribución de los valores verdaderos en la población. Suponga ahora que se observa una lista A, de modo que para la variable k se registra un valor observado A_k, el cual puede diferir del valor verdadero debido a errores de medición.

Condicionando en que el valor verdadero de la variable es $Y_k = y$, el modelo de medición para A_k se define como:

$$P(A_k = a \mid Y_k = y) = \begin{cases} \alpha_k & \text{si } a = y, \\ (1 - \alpha_k)\, f_k(a) & \text{si } a \neq y. \end{cases}$$

Es decir, dado que el valor verdadero es y, entonces: con probabilidad α_k, el proceso de medición es correcto y se observa el mismo valor, es decir, $A_k = y$; además, con probabilidad $1 - \alpha_k$, ocurre un error de medición, por lo que el valor observado A_k toma un valor distinto de y.

En este último caso, los posibles valores erróneos se distribuyen según $f_k(a)$, la cual está definida sobre los valores $a \neq y$ y satisface que

$$\sum_{a \neq y} f_k(a) = 1.$$

Por tanto, $1 - \alpha_k$ representa la probabilidad total de observar la variable con error, mientras que $f_k(a)$ describe cómo se distribuyen dichos errores entre las categorías posibles.

Consideremos un ejemplo sencillo para ilustrar el modelo de error de medición en el caso discreto. Suponga que la variable verdadera toma valores en el conjunto

$$Y_k \in \{1, 2, 3\},$$

y que para una unidad específica se tiene que el valor verdadero es $Y_k = 2$. Además, suponga que la probabilidad de observar correctamente el valor verdadero es $\alpha_k = 0.8$. Esto significa que, con probabilidad 0.8, el valor observado coincide con el verdadero.

Cuando ocurre un error, lo cual sucede con probabilidad $1 - \alpha_k = 0.2$, el valor observado se genera según una distribución discreta $f_k(a)$ definida únicamente sobre los valores incorrectos. En este ejemplo, asumimos:

$$f_k(a) = \begin{cases} 0.6 & \text{si } a = 1, \\ 0.4 & \text{si } a = 3. \end{cases}$$

Es decir, dado que ocurrió un error, el valor observado será 1 con probabilidad 0.6 y 3 con probabilidad 0.4. Bajo este esquema, la distribución condicional de $A_k \mid Y_k = 2$ queda dada por:

$$P(A_k = a \mid Y_k = 2) = \begin{cases} 0.8 & \text{si } a = 2, \\ 0.2 \cdot 0.6 = 0.12 & \text{si } a = 1, \\ 0.2 \cdot 0.4 = 0.08 & \text{si } a = 3. \end{cases}$$

En otras palabras, el valor observado coincide con el verdadero con alta probabilidad, mientras que los errores se distribuyen entre las otras categorías según $f_k(a)$. Finalmente, se verifica rápidamente que esta es una distribución de probabilidad válida, puesto que $0.8 + 0.12 + 0.08 = 1$. Esto confirma que el modelo está correctamente normalizado, ya que la probabilidad total sobre todos los valores posibles de A_k es igual a uno.

Formulación con dos listas

Sea A y B dos listas que contienen registros de unidades, y sea A_k y B_k los valores observados de la variable k en cada una de ellas. Como se ha definido a lo largo de este documento, para modelar la relación entre los registros de ambas listas, se introduce una variable indicadora Z ($Z = 1$ indica que los registros corresponden a la misma unidad, mientras que $Z = 0$ indica que corresponden a unidades distintas).

La estructura del modelo de Copas-Hilton depende crucialmente del valor de Z. Cuando $Z = 1$, se asume que ambos registros provienen de la misma unidad en la población, por lo que comparten un mismo valor verdadero latente para la variable k. En este caso, si denotamos por $Y_k^{(A)}$ y $Y_k^{(B)}$ como los valores verdaderos asociados a los registros en las listas A y B, respectivamente, se tiene que ambos coinciden y pueden representarse mediante una única variable latente Y_k, es decir,

$$Y_k^{(A)} = Y_k^{(B)} = Y_k.$$

Esto refleja que cualquier discrepancia entre A_k y B_k se debe exclusivamente a errores de medición y no a diferencias reales en el valor subyacente.

Por el contrario, cuando $Z = 0$, los registros en A y B corresponden a unidades distintas de la población. En este caso, no existe razón para suponer que los valores verdaderos estén relacionados, por lo que se modelan como variables independientes. Es decir, los valores verdaderos $Y_k^{(A)}$ y $Y_k^{(B)}$ se generan de manera independiente según la distribución poblacional de la variable, lo cual se expresa como $Y_k^{(A)} \perp Y_k^{(B)}$.

Esta distinción entre los casos $Z = 1$ y $Z = 0$ es fundamental, ya que define la estructura probabilística de esta formulación al problema de *record linkage*, permitiendo diferenciar entre coincidencias reales y coincidencias espurias a partir de los valores observados.

Probabilidades de coincidencia

Para calcular la probabilidad de coincidencia entre A_k y B_k condicionada en un valor verdadero $Y_k = y$, es necesario analizar los distintos mecanismos a través de los cuales puede ocurrir el evento $A_k = B_k$. En este contexto, el modelo asume que cada registro puede observar correctamente el valor verdadero con probabilidad α_k, o bien cometer un error con probabilidad $1 - \alpha_k$, en cuyo caso el valor observado se genera según la distribución marginal $f_k(\cdot)$.

Bajo este esquema, el evento $A_k = B_k$ puede darse esencialmente de dos formas. La primera corresponde al caso en que ambos registros observan correctamente el valor verdadero (**hit-hit**). En este escenario, tanto A_k como B_k toman el valor y, y dado que los errores son independientes entre fuentes, la probabilidad de este evento es:

$$P(A_k = y, B_k = y \mid Y_k = y) = \alpha_k^2$$

La segunda posibilidad es que ambos registros cometan un error (**miss-miss**), pero aun así coincidan en el mismo valor incorrecto. Es decir, existe algún valor $a \neq y$ tal que $A_k = a$ y $B_k = a$. En este caso, cada registro falla con probabilidad $1-\alpha_k$, y luego ambos generan el mismo valor a de acuerdo con la distribución $f_k(a)$. Nuevamente, por independencia, la probabilidad de este evento es:

$$P(A_k = a, B_k = a \mid Y_k = y, a \neq y) = (1-\alpha_k)^2 f_k(a)^2$$

Para obtener la probabilidad total de coincidencia $P(A_k = B_k \mid Y_k = y)$, se deben sumar todas las formas en que puede ocurrir este evento. Esto incluye tanto el caso en que ambos aciertan como todos los posibles valores incorrectos en los que ambos podrían coincidir. Por lo tanto:

$$\begin{aligned} P(A_k = B_k \mid Y_k = y) &= \alpha_k^2 + (1-\alpha_k)^2 \sum_{a \neq y} f_k(a)^2 \\ &= \alpha_k^2 + (1-\alpha_k)^2 \left[\sum_a f_k(a)^2 - f_k(y)^2 \right] \end{aligned}$$

Lo anterior, puesto que, la suma sobre $a \neq y$ puede reescribirse de manera más conveniente separando el término correspondiente a y de la suma total sobre todos los valores posibles. Ahora, promediando respecto a la distribución de Y_k, se obtiene una expresión para la probabilidad marginal de coincidencia bajo el caso $Z = 1$. En efecto, se tiene que

$$\begin{aligned} P(X_k = 1 \mid Z = 1) &= P(A_k = B_k \mid Z = 1) \\ &= \sum_y P(A_k = B_k, Y_k = y \mid Z = 1) \\ &= \sum_y P(Y_k = y \mid Z = 1)\, P(A_k = B_k \mid Y_k = y, Z = 1) \\ &= \sum_y f_k(y)\, P(A_k = B_k \mid Y_k = y) \end{aligned}$$

Nótese que la última igualdad asume que : (i) $P(Y_k = y \mid Z = 1) = f_k(y)$, y (ii) $P(A_k = B_k \mid Y_k = y, Z = 1) = P(A_k = B_k \mid Y_k = y)$.

Sustituyendo la expresión anterior dentro de la suma, obtenemos:

$$\begin{aligned} P(X_k = 1 \mid Z = 1) &= \sum_y f_k(y) \left[\alpha_k^2 + (1-\alpha_k)^2 \left(\sum_a f_k(a)^2 - f_k(y)^2 \right) \right] \\ &= \sum_y f_k(y)\, \alpha_k^2 + (1-\alpha_k)^2 \sum_y f_k(y) \left(\sum_a f_k(a)^2 - f_k(y)^2 \right) \\ &= \alpha_k^2 \sum_y f_k(y) + (1-\alpha_k)^2 \left[\sum_y f_k(y) \sum_a f_k(a)^2 - \sum_y f_k(y)^3 \right] \\ &= \alpha_k^2 + (1-\alpha_k)^2 \left[\sum_a f_k(a)^2 \sum_y f_k(y) - \sum_y f_k(y)^3 \right] \\ &= \alpha_k^2 + (1-\alpha_k)^2 \left[\sum_a f_k(a)^2 - \sum_y f_k(y)^3 \right] \end{aligned}$$

En la práctica, es común utilizar una aproximación que simplifica esta expresión. En particular, se suele ignorar el término $\sum_y f_k(y)^3$, lo que lleva a la siguiente forma aproximada para la probabilidad de coincidencia en el caso de match:

$$m_k = P(X_k = 1 \mid Z = 1) \approx \alpha_k^2 + (1 - \alpha_k)^2 \sum_y f_k(y)^2$$

Por otro lado, también se quiere derivar la probabilidad de coincidencia dado que los registros no corresponden a la misma unidad. Es decir:

$$u_k = P(X_k = 1 \mid Z = 0) = P(A_k = B_k)$$

Teniendo en cuenta que, bajo $Z = 0$, los registros son independientes y que, bajo el modelo de medición, se asume que tanto A_k como B_k siguen la misma distribución marginal ($P(A_k = a) = P(B_k = a) = f_k(a)$), podemos expresar esta probabilidad como la suma sobre todos los posibles valores a. Así:

$$\begin{aligned} P(A_k = B_k) &= \sum_a P(A_k = a, B_k = a) \\ &= \sum_a P(A_k = a)\, P(B_k = a) \\ &= \sum_a f_k(a)\, f_k(a) \\ &= \sum_a f_k(a)^2 \end{aligned}$$

Por lo tanto, obtenemos:

$$u_k = P(X_k = 1 \mid Z = 0) = \sum_a f_k(a)^2$$

El término $\sum_a f_k(a)^2$ puede interpretarse como la probabilidad de que dos valores independientes, generados desde la misma distribución f_k, coincidan por azar.

Razón de verosimilitudes

Partiendo de la variable indicadora X_k, que toma valor 1 si hay acuerdo en el campo k y 0 en caso contrario, se tiene que, luego de marginalizar la variable latente Y_k, la distribución de X_k condicional en el estado de enlace Z toma una forma Bernoulli. En particular, cuando los registros corresponden a la misma unidad ($Z = 1$), la probabilidad de acuerdo está dada por m_k, por lo que:

$$P(X_k = x_k \mid Z = 1) = m_k^{x_k}(1 - m_k)^{1-x_k}.$$

De manera análoga, cuando los registros no corresponden a la misma unidad ($Z = 0$), la probabilidad de acuerdo está dada por u_k, y por tanto:

$$P(X_k = x_k \mid Z = 0) = u_k^{x_k}(1 - u_k)^{1-x_k}.$$

Acudiendo al supuesto de independencia condicional entre los campos, dado el estado de enlace Z, el vector de comparaciones $X = (X_1, \ldots, X_K)$ se tiene que:

$$P(X \mid Z) = \prod_{k=1}^{K} P(X_k \mid Z).$$

Este supuesto permite construir la razón de verosimilitudes, que compara la evidencia a favor de que un par de registros corresponda a la misma unidad frente a que no lo sea. Esta razón está definida como:

$$\Lambda(X) = \frac{P(X \mid Z = 1)}{P(X \mid Z = 0)}.$$

Sustituyendo las expresiones anteriores para cada componente X_k, obtenemos una forma multiplicativa:

$$\Lambda(X) = \prod_{k=1}^{K} \left(\frac{m_k}{u_k}\right)^{x_k} \left(\frac{1 - m_k}{1 - u_k}\right)^{1-x_k}.$$

Finalmente, para facilitar la interpretación y el cálculo, es común trabajar con el logaritmo de la razón de verosimilitudes. Al tomar logaritmos, el producto se transforma en una suma:

$$\log \Lambda(X) = \sum_{k=1}^{K} \left[x_k \log\left(\frac{m_k}{u_k}\right) + (1 - x_k) \log\left(\frac{1 - m_k}{1 - u_k}\right) \right].$$

Esta última expresión es especialmente útil, ya que muestra que la evidencia total a favor del enlace es la suma de contribuciones aditivas de cada campo, lo que constituye la base de los métodos clásicos de clasificación en record linkage probabilístico.